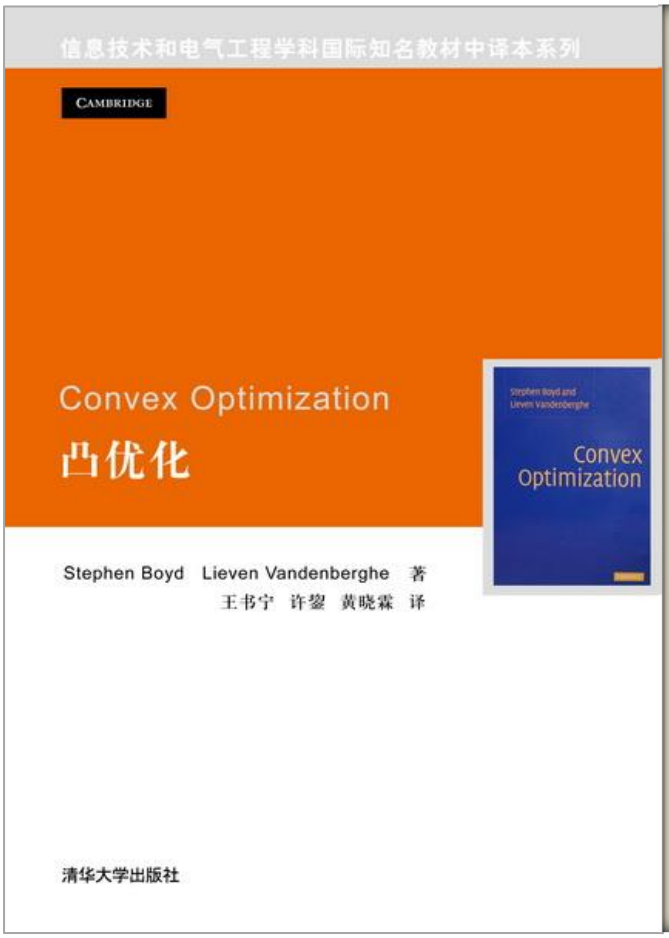
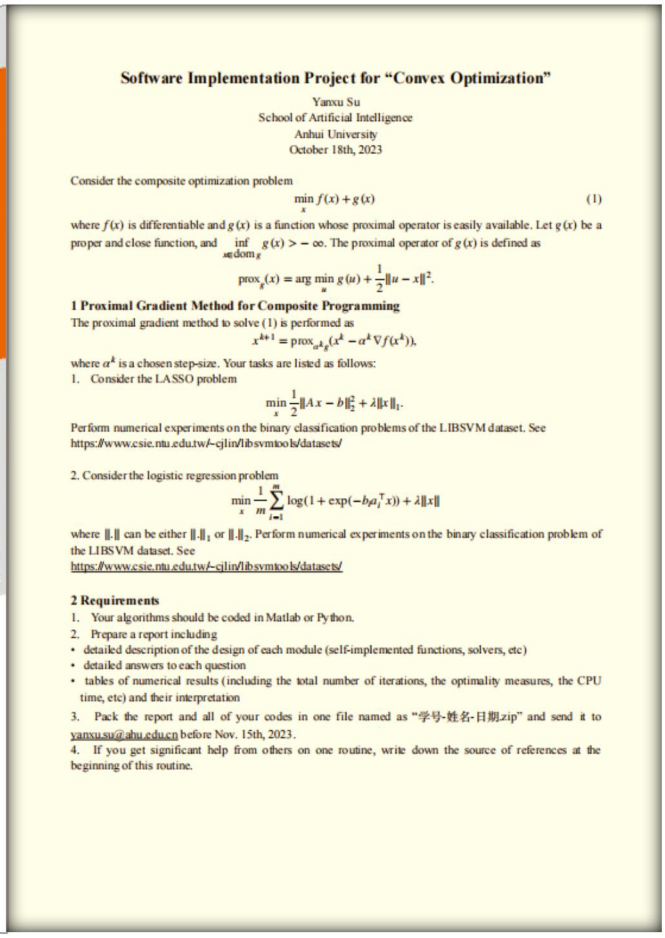
凸优化大作业教程





Software Implementation Project for "Convex Optimization"

Yanxu Su
School of Artificial Intelligence
Anhui University
October 18th, 2023

Consider the composite optimization problem

$$\min_x f(x) + g(x) \tag{1}$$

where $f(x)$ is differentiable and $g(x)$ is a function whose proximal operator is easily available. Let $g(x)$ be a proper and close function, and $\inf_{x \in \mathrm{dom}\, g} g(x) > -\infty$. The proximal operator of $g(x)$ is defined as

$$\mathrm{prox}_g(x) = \arg\min_u g(u) + \frac{1}{2}\|u - x\|^2.$$

1 Proximal Gradient Method for Composite Programming

The proximal gradient method to solve (1) is performed as

$$x^{k+1} = \mathrm{prox}_{\alpha^k g}(x^k - \alpha^k \nabla f(x^k)),$$

where α^k is a chosen step-size. Your tasks are listed as follows:

1. Consider the LASSO problem

$$\min_x \frac{1}{2}\|Ax - b\|_2^2 + \lambda\|x\|_1.$$

Perform numerical experiments on the binary classification problems of the LIBSVM dataset. See https://www.csie.ntu.edu.tw/~cjlin/libsvmtools/datasets/

2. Consider the logistic regression problem

$$\min_x \frac{1}{m}\sum_{i=1}^{m} \log(1 + \exp(-b_i a_i^T x)) + \lambda\|x\|$$

where $\|.\|$ can be either $\|.\|_1$ or $\|.\|_2$. Perform numerical experiments on the binary classification problem of the LIBSVM dataset. See https://www.csie.ntu.edu.tw/~cjlin/libsvmtools/datasets/

2 Requirements

1. Your algorithms should be coded in Matlab or Python.
2. Prepare a report including
   - detailed description of the design of each module (self-implemented functions, solvers, etc)
   - detailed answers to each question
   - tables of numerical results (including the total number of iterations, the optimality measures, the CPU time, etc) and their interpretation
3. Pack the report and all of your codes in one file named as "学号-姓名-日期.zip" and send it to yanxu.su@ahu.edu.cn before Nov. 15th, 2023.
4. If you get significant help from others on one routine, write down the source of references at the beginning of this routine.

王晗宇

2025/3/28

（一）我们先拆解一下大作业文档

- **首先给了 3 个问题和算法的定义**

[1] **定义 1：复合优化问题**

$$\min_x f(x) + g(x)$$

目标是最小化两个函数 f(x)和 g(x)的和。
条件：
$f(x)$是可微的。
$g(x)$是一个其近端算子容易计算的函数。
$g(x)$是一个适当且闭合的函数，即$g(x)$是一个凸函数，并且在其定义域内是下半连续的。

[2] **定义 2：近端算子$\text{prox}_g(x)$**

$$\text{prox}_g(x) = \arg\min_u \left[g(u) + \frac{1}{2}|u - x|^2 \right]$$

并且说这个算子在优化问题中用于处理非光滑部分$g(x)$，特别是在下面的近端梯度方法[3]中。

[3] **定义 3：近端梯度方法**

$$x_{k+1} = \text{prox}_{\alpha_k g}\left(x_k - \alpha_k \nabla f(x_k)\right)$$

是一个迭代公式，用于求解复合优化问题[1]。

[3]中：
x_k是第k次迭代的当前点。
α_k是选择的步长，通常是一个正数。
$\nabla f(x_k)$是$f(x)$在x_k处的梯度。
$\text{prox}_{\alpha_k g}$是$\alpha_k g$的近端算子。

[3]步骤拆解：
1. 计算$f(x)$在当前点x_k处的梯度$\nabla f(x_k)$。
2. 使用步长α_k对梯度进行缩放，得到$\alpha_k \nabla f(x_k)$。
3. 从当前点x_k减去这个缩放后的梯度，得到$x_k - \alpha_k \nabla f(x_k)$。
4. 应用近端算子[2]$\text{prox}_{\alpha_k g}$到 3 的结果，得到下一个迭代点x_{k+1}。

- **接下来说明我们要实现的任务**

我们需要用数据集编程实现优化问题，具体步骤包括：
1. 数据集处理(明确数据的**输入特征**和**真实值(标签)**)；（数据说明我放在了下一节介绍）
2. 初始化算法模型**(参数)**，以及设置优化算法(近端梯度方法[3])的步长α_k等**超参数**；
3. 训练算法模型(参数)，将数据输入特征输入模型，得出结果(**预测值**)；
4. 通过优化算法(近端梯度方法[3])，根据预测值和真实值(标签)的差异反向更新模型参数

5. 迭代 3、4，直到满足停止条件（如最大迭代次数达到或目标函数值变化小于某个阈值）
6. 用另一批数据测试优化好的模型准确率(看预测值和真实值(标签)的差异情况)

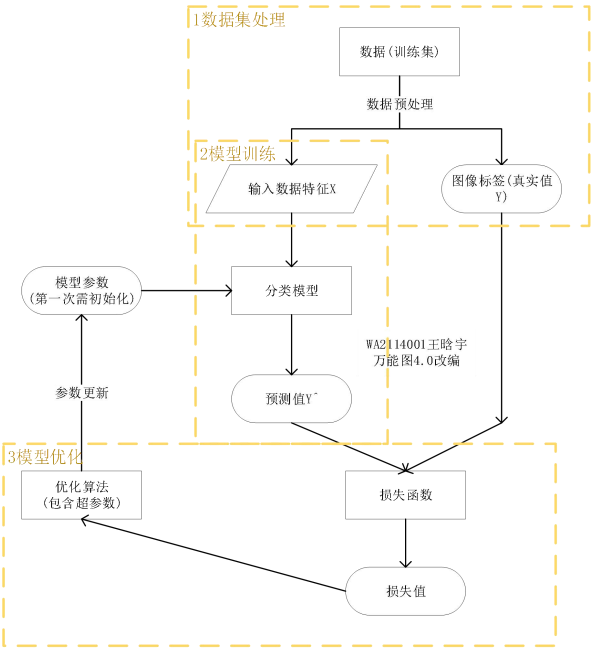


图 1：训练模型

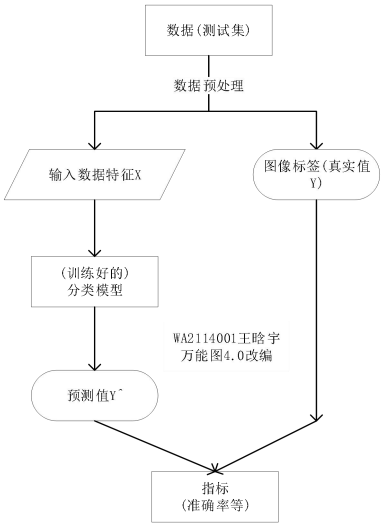


图 2：测试模型

下面具体说明要实现的两个问题

（1）LASSO 问题

$$\min_x \frac{1}{2}||Ax-b||_2^2+\lambda||x||_1$$

（它常用于用于线性回归中的特征选择和正则化）。

解释：

A是输入的数据输入特征矩阵(m*n)，行数 m 是数据**样本个数**，列数 n 说明数据有 n 个特征(比如数据如果是一个人则有身高、体重、年龄等 n 个特征)，b是每个数据真实值(标签)组成的向量(m*1)，x是模型参数(n*1)；

$\frac{1}{2}||Ax-b||_2^2$是最小二乘损失项，衡量预测值Ax与真实值b之间的误差；

$\lambda||x||_1$是 L1 正则化项，许多系数为零，从而实现特征选择；
λ是正则化超参数，控制正则化项的权重；

然后让用 LIBSVM 数据集，下载地址：
https://www.csie.ntu.edu.tw/~cjlin/libsvmtools/datasets/

（2）逻辑回归问题

$$\min_x \frac{1}{m}\sum_{i=1}^{m}\log\left(1+\exp\left(-b_i a_i^T x\right)\right)+\lambda||x||$$

（它用于二分类任务，结合了逻辑损失和正则化项）。
解释：
a_i是输入的第i个(总共m个)数据样本输入特征向量(n*1)（一般单个数据都写成列向量），行数 n 说明数据有 n 个特征(比如数据如果是一个人则有身高、体重、年龄等 n 个特征)，b_i是每个数据真实值(标签)(1*1 标量)，x是模型参数 (n*1)；

$\frac{1}{m}\sum_{i=1}^{m}\log\left(1+\exp\left(-b_i a_i^T x\right)\right)$是逻辑损失函数，衡量模型预测的概率与真实标签$b_i$之间的差异。
$\lambda||x||$是正则化项，可以是 L1 范数$||x||_1$或 L2 范数$||x||_2$，用于防止过拟合。
λ是正则化超参数，控制正则化项的权重。
a_i是第i个样本的特征向量，b_i是第i个样本的标签（通常取值为+1 或-1）。

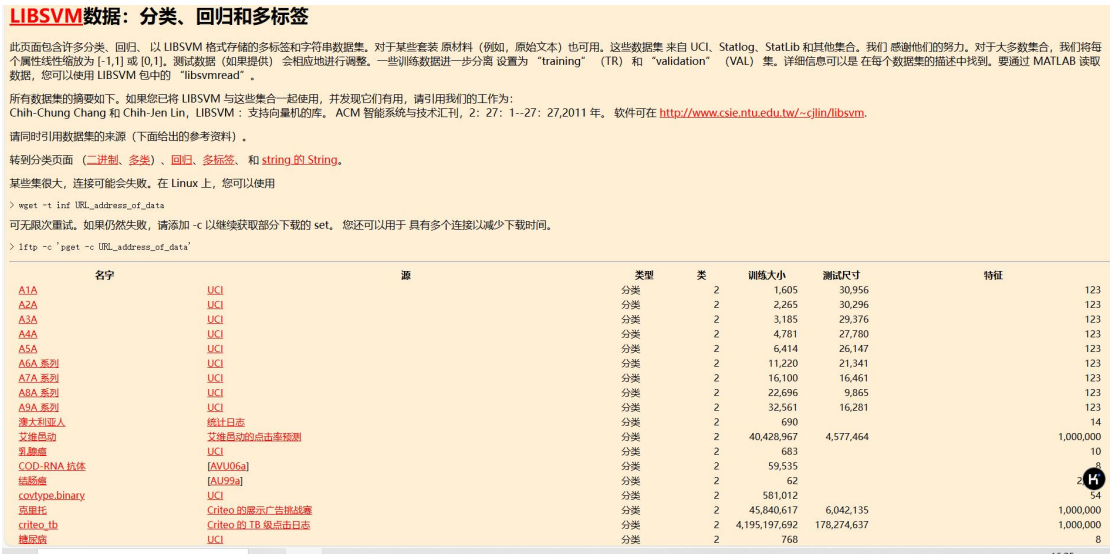
这个问题数据集同上[链接]

- **最后说了大作业要求**

1. 算法用 Matlab 或 Python 编写。
2. 准备一份报告，包括：
- 每个模块设计的详细描述（自行实现的函数、求解器等）
- 每个问题的详细答案
- 数值结果表（包括迭代总数、最优性度量、CPU 时间等）及其解释
3. 将报告和所有代码打包成一个文件，文件名为“**学号-姓名-日期.zip**”
并于 20XX 年 1X 月 X5 日前发送至 yanxu.su@ahu.edu.cn。
4. 如果您在某个例程上得到他人的重大帮助，请在该例程开头写下参考资料来源。

（二）数据集介绍

LIBSVM 数据集 [链接]点开是这样的



LIBSVM数据：分类、回归和多标签

此页面包含许多分类、回归、以 LIBSVM 格式存储的多标签和字符串数据集。对于某些套装 原材料（例如，原始文本）也可用。这些数据集 来自 UCI、Statlog、StatLib 和其他集合。我们 感谢他们的努力。对于大多数集合，我们将每个属性线性缩放为 [-1,1] 或 [0,1]。测试数据（如果提供） 会相应地进行调整。一些训练数据进一步分离 设置为 “training” （TR） 和 “validation” （VAL） 集。详细信息可以是 在每个数据集的描述中找到。要通过 MATLAB 读取数据，您可以使用 LIBSVM 包中的 “libsvmread” 。

所有数据集的摘要如下。如果您已将 LIBSVM 与这些集合一起使用，并发现它们有用，请引用我们的工作为：
Chih-Chung Chang 和 Chih-Jen Lin，LIBSVM ： 支持向量机的库。 ACM 智能系统与技术汇刊，2：27：1--27：27,2011 年。 软件可在 http://www.csie.ntu.edu.tw/~cjlin/libsvm.

请同时引用数据集的来源（下面给出的参考资料）。

转到分类页面 （二进制、多类）、回归、多标签、和 string 的 String。

某些集很大，连接可能会失败。在 Linux 上，您可以使用

```
> wget -t inf URL_address_of_data
```

可无限次重试。如果仍然失败，请添加 -c 以继续获取部分下载的 set。 您还可以用于 具有多个连接以减少下载时间。

```
> lftp -c 'pget -c URL_address_of_data'
```

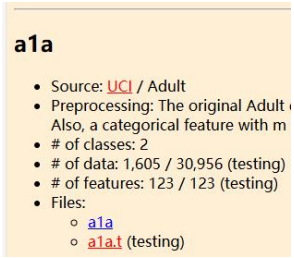
名字	源	类型	类	训练大小	测试尺寸	特征
A1A	UCI	分类	2	1,605	30,956	123
A2A	UCI	分类	2	2,265	30,296	123
A3A	UCI	分类	2	3,185	29,376	123
A4A	UCI	分类	2	4,781	27,780	123
A5A	UCI	分类	2	6,414	26,147	123
A6A 系列	UCI	分类	2	11,220	21,341	123
A7A 系列	UCI	分类	2	16,100	16,461	123
A8A 系列	UCI	分类	2	22,696	9,865	123
A9A 系列	UCI	分类	2	32,561	16,281	123
澳大利亚人	统计日志	分类	2	690		14
艾维恩动	艾维恩动的点击率预测	分类	2	40,428,967	4,577,464	1,000,000
乳腺癌	UCI	分类	2	683		10
COD-RNA 抗体	[AVU06a]	分类	2	59,535		8
结肠癌	[AU99a]	分类	2	62		2
covtype.binary	UCI	分类	2	581,012		54
克里托	Criteo 的展示广告挑战赛	分类	2	45,840,617	6,042,135	1,000,000
criteo_tb	Criteo 的 TB 级点击日志	分类	2	4,195,197,692	178,274,637	1,000,000
糖尿病	UCI	分类	2	768		8

我们可以下载合适的二分类数据集，例如 breast-cancer, diabetes, heart 等。
它的数据格式如下：
文本文件(.txt)形式存储，每行表示一个样本，
格式为 `label feature_index:feature_value ...`
（例如 `1 1:0.5 2:0.3` 表示真实值(标签)为 1，输入特征的第一个特征值为 0.5，第二个特征值为 0.3）
那个特征值索引(1:,2:之类的)自行想办法去掉就行

类型	类	训练大小	测试尺寸	特征
分类	2	1,605	30,956	123
分类	2	2,265	30,296	123
分类	2	3,185	29,376	123

类是指真实值(标签)的取值个数（如果是 2 就说明是二分类，标签只有+1，-1）；
训练大小指的是训练数据集中的样本数量 m;
测试尺寸指的是测试数据集中的样本数量;
特征指的是每个样本的特征数量 n;

下载：点开数据 name 之后点 Files 分别下载训练集和测试集



a1a

- Source: UCI / Adult
- Preprocessing: The original Adult
  Also, a categorical feature with m
- # of classes: 2
- # of data: 1,605 / 30,956 (testing)
- # of features: 123 / 123 (testing)
- Files:
  - a1a
  - a1a.t (testing)

（三）代码实现(Python 版)


肝不动了！